

Projet Annuel MASTER 2 INFO
USPN – 2025-2026
M. F. BOUFARES

Des données **NON structurées** vers les données **structurées**

Les LLM au service de la cosmétovigilance

Les LLM au service du remplissage des BD hospitalières

Construire un système d'analyse automatisée de documents (tels que des rapports PDF, DOC, XL) centré sur les **données des organisations** (telles que les entreprises, les hôpitaux) pour construire un dataset (BD) structuré sur ces dernières.

Explication des termes (LLM, Agent, Chatbot, RAG) dans le cadre du projet d'analyse de documents des organisations :

LLM (Large Language Model)

- **Définition** : Un **modèle de langage de grande taille** est une intelligence artificielle entraînée sur de grandes quantités de textes pour comprendre et générer du langage naturel.
- **Exemple** : Si on devait s'intéresser sur les données climatiques des entreprises, un LLM (comme ChatGPT) peut lire des documents tels que PDF ou TXT, extraire des informations pertinentes (ex. : chiffres d'émissions de CO₂, secteur d'activité, taille de l'entreprise, politiques RSE) et aider à structurer ces données dans un tableau ou une base de données.

Agent

- **Définition** : Un **agent** est une entité autonome qui peut planifier, raisonner et exécuter des tâches de manière séquencée, souvent en utilisant un ou plusieurs LLM.
- **Exemple** : On pourrait utiliser un agent pour :
 - Lire chaque fichier (PDF ou autre) automatiquement.
 - Identifier les informations pertinentes.
 - Poser des questions s'il manque des données.
 - Ajouter les données extraites dans un format structuré (tel que CSV, JSON).

Chatbot


- **Définition** : Un **chatbot** est une interface conversationnelle automatisée, souvent basée sur un LLM, avec laquelle un humain peut dialoguer.
- **Exemple** : Un chatbot peut permettre d'interroger les documents ("Quelle est l'empreinte carbone de l'entreprise X ?") de manière interactive, mais il ne planifie pas de tâches complexes par lui-même comme un agent.

RAG (Retrieval-Augmented Generation)

- **Définition** : Une méthode d'IA où un modèle de langage (LLM) **va chercher de l'information dans une base de données ou un corpus de documents** avant de générer une réponse.
 - **Retrieval** = aller chercher de l'information dans les documents.
 - **Augmented Generation** = utiliser ces informations pour produire une réponse pertinente.
- **Exemple** : Si l'on a des centaines de PDF, un système RAG peut être mis en place pour :
 - Indexer tous les documents.
 - Retrouver les passages pertinents selon la question ou le besoin.
 - Générer une réponse ou une donnée à inclure dans le dataset.

En résumé :

Terme	Rôle principal
LLM	Comprendre et extraire des données depuis les documents de départ (PDF, DOC, TXT...)
Agent	Enchaîner plusieurs tâches automatiquement (lecture, extraction, structuration)
Chatbot	Permettre d'interagir avec les données ou les documents par conversation
RAG	Aller chercher l'information dans les documents de départ avant de générer une réponse pertinente



Objectif de l'étude exemple : Construire une structure de base de données (BD) adaptée à l'analyse de documents pour le **reporting climatique des entreprises européennes par exemple**.

Créer une **base de données relationnelle** (ou structurée en format type CSV/JSON) permettant de stocker et d'analyser les **informations extraites** des rapports tels que les bilans RSE, rapports extra-financiers, rapports d'activité.

1. Les types d'informations à extraire : catégories principales d'information pertinentes pour l'étude :

Identification de l'entreprise

- company_name : Nom de l'entreprise ;
- siret / siren / vat_number : Identifiants légaux
- country / region : Localisation
- industry_sector : Secteur d'activité (ex. NAF/APE ou GICS/NACE)
- company_size : Taille (PME, ETI, GE)
- number_of_employees

Données financières (facultatif mais utile)

- turnover : Chiffre d'affaires
- net_income : Résultat net
- ebitda

Données environnementales

- total_emissions_tCO2e : Total émissions de GES (en tonnes équivalent CO₂)
- scope_1_emissions : Emissions directes (Scope 1)
- scope_2_emissions : Emissions indirectes liées à l'énergie (Scope 2)
- scope_3_emissions : Autres émissions indirectes (Scope 3)
- carbon_neutrality_target_year : Année visée pour la neutralité carbone

Politiques et engagements RSE

- has_sustainability_policy : Politique RSE (booléen)
- esg_goals : Objectifs ESG/RSE (texte ou JSON structuré)

- climate_risk_management : Description des mesures face au risque climatique
- certifications : Ex. : ISO 14001, B Corp, etc.

Références au rapport

- report_title
- report_year
- report_source : URL ou fichier PDF
- extraction_date
- page_reference : pages du rapport contenant les infos

2. Proposition de schéma de base de données exemple

On pourrait commencer avec 3 tables principales :

◆ companies (Informations de base sur l'entreprise)

Field	Type	Description	Contraintes
id	UUID / INT	Identifiant unique	
company_name	TEXT	Nom de l'entreprise	
siret	TEXT	Numéro SIRET	
country	TEXT	Pays	
industry_sector	TEXT	Secteur d'activité	
company_size	TEXT	PME / ETI / GE	
number_of_employees	INTEGER	Nombre de salariés	

◆ climate_reports (Données par rapport/climat)

Field	Type	Description	Contraintes
id	UUID / INT	Identifiant unique	
company_id	FK	Clé étrangère vers companies	
report_year	INTEGER	Année du rapport	
report_title	TEXT	Titre du document PDF	
scope_1_emissions	FLOAT	Emissions Scope 1 (tCO ₂ e)	
scope_2_emissions	FLOAT	Emissions Scope 2	
scope_3_emissions	FLOAT	Emissions Scope 3	
total_emissions	FLOAT	Total émissions	
carbon_neutrality_target	INTEGER	Année objectif neutralité carbone (si dispo)	
page_reference	TEXT	Pages contenant les infos	

◆ sustainability_policies (Engagements et politiques RSE)

Field	Type	Description	Contraintes
id	UUID	Identifiant	
company_id	FK	Référence à companies	
has_sustainability_policy	BOOLEAN	L'entreprise a-t-elle une politique RSE ?	
esg_goals	TEXT	Objectifs RSE/ESG	
climate_risk_management	TEXT	Description du pilotage des risques climatiques	
certifications	TEXT	ISO, B Corp, etc.	

On pourra stocker temporairement les données en : **CSV/Excel** (pour visualisation rapide), **SQLite** (léger, local), **PostgreSQL**, Oracle, ou même en **JSON**.

Étapes pour remplir la BD depuis des documents PDF

1. **Extraction du texte des documents de départ en PDF par exemple** → avec des outils comme pdfplumber, PyMuPDF, ou des solutions OCR si scannés.
2. **Pré-traitement et parsing** → repérage des zones contenant les données.
3. **Extraction avec LLM ou RAG** → extraire les champs utiles.
4. **Validation humaine ou semi-automatisée** (important dans un contexte scientifique).
5. **Insertion dans la BD.**

Exemple fait avec ChatGPT (Il n'a pas été testé) :

Étape 1 – Modèle de base de données (en SQL / SQLite)

Voici un **script SQL** utilisable pour créer ta base dans **SQLite** :

-- Table des entreprises

```
CREATE TABLE companies (id INTEGER PRIMARY KEY AUTOINCREMENT,  
    company_name TEXT NOT NULL, siret TEXT, country TEXT, industry_sector TEXT, company_size TEXT,  
    number_of_employees INTEGER);
```

-- Table des rapports climat

```
CREATE TABLE climate_reports (id INTEGER PRIMARY KEY AUTOINCREMENT,  
    company_id INTEGER, report_year INTEGER, report_title TEXT,  
    scope_1_emissions REAL, scope_2_emissions REAL, scope_3_emissions REAL, total_emissions REAL,  
    carbon_neutrality_target INTEGER, page_reference TEXT,  
    FOREIGN KEY (company_id) REFERENCES companies(id));
```

-- Table des politiques RSE

```
CREATE TABLE sustainability_policies (id INTEGER PRIMARY KEY AUTOINCREMENT,  
    company_id INTEGER, has_sustainability_policy BOOLEAN, esg_goals TEXT,  
    climate_risk_management TEXT, certifications TEXT,  
    FOREIGN KEY (company_id) REFERENCES companies(id));
```

On pourrait exécuter ce script avec un outil comme [DB Browser for SQLite](#) ou directement dans un script Python.

Étape 2 – Script Python de base pour extraire et remplir la BD

Ci-dessous un **script Python minimal** pour Lire un PDF, Extraire du texte (avec PyMuPDF) et Ajouter des données extraites dans SQLite.

Installation des prérequis : pip install fitz PyMuPDF sqlite3

Exemple de script Python :

```
import fitz # PyMuPDF
import sqlite3

# Connexion à la base de données
conn = sqlite3.connect("climate_reporting.db")
cursor = conn.cursor()

# Exemple : Extraction texte d'un PDF
def extract_text_from_pdf(pdf_path):
    text = ""
    with fitz.open(pdf_path) as doc:
        for page in doc:
            text += page.get_text()
    return text

# Supposons qu'on ait manuellement extrait quelques champs pour tester :
def insert_test_data():
    # Ajout entreprise
    cursor.execute("""
        INSERT INTO companies (company_name, siret, country, industry_sector, company_size, number_of_employees)
        VALUES (?, ?, ?, ?, ?, ?)
        """, ("Société ExEco", "12345678901234", "France", "Énergie", "ETI", 850))

    company_id = cursor.lastrowid

    # Ajout rapport climatique
    cursor.execute("""
        INSERT INTO climate_reports (company_id, report_year, report_title, scope_1_emissions,
        scope_2_emissions, scope_3_emissions, total_emissions, carbon_neutrality_target, page_reference)
        VALUES (?, ?, ?, ?, ?, ?, ?, ?, ?)
        """, (company_id, 2023, "Rapport RSE 2023", 1200.5, 850.2, 5300.7, 7351.4, 2030, "pages 12-15"))

    # Ajout politique RSE
    cursor.execute("""
        INSERT INTO sustainability_policies (company_id, has_sustainability_policy, esg_goals,
        climate_risk_management, certifications)
        VALUES (?, ?, ?, ?, ?)
        """, (company_id, True, "Réduction de 40% CO2 d'ici 2028", "Suivi via comité climat trimestriel", "ISO 14001"))

    conn.commit()

# Exemple usage
pdf_text = extract_text_from_pdf("rapport_exemple.pdf")
# (On pourrait ensuite utiliser un LLM ici pour analyser `pdf_text`)

insert_test_data()
print("Exemple inséré.")
```

Étape(s) suivante(s) dont les objectifs sont :

Le traitement de plusieurs fichiers en entrée, l'extraction des données elles-mêmes et l'insertion dans la BD.
On pourrait utiliser : Soit un LLM comme GPT via une API OpenAI ou HuggingFace pour extraire les valeurs (telle que Scope 1 : 1234 tCO₂e) ; Soit une approche RAG avec indexation de tous les PDF.

A vous la suite...

Bon courage

Exemple de BD **fictive** avec quelques entreprises, issue de quelques rapports fictifs PDF.

Rapport Climat – Entreprise 1 : Énergies Gaïa Rapport Climat – Énergies Gaïa Année : 2023 Nom de l'entreprise : Énergies Gaïa SIRET : 48765432100033 Secteur : Production d'énergie renouvelable Taille : PME Nombre d'employés : 180 Bilan Carbone : - Scope 1 : 1 250 tCO₂e - Scope 2 : 980 tCO₂e - Scope 3 : 5 320 tCO₂e - Total : 7 550 tCO₂e Objectifs climatiques : - Neutralité carbone visée pour 2040 - Réduction de 30 % des émissions totales d'ici 2030 RSE : - Engagement ESG : investissement dans les éoliennes marines, programmes locaux d'éducation - Certification : ISO 14001, Label LUCIE Gestion des risques : - Analyse annuelle des risques climatiques physiques (sécheresses, inondations)
Rapport Climat – Entreprise 2 : Groupe Teralog Rapport Développement Durable – Groupe Teralog Année de publication : 2024 Nom : Groupe Teralog SIRET : 92345678100021 Secteur : Technologies numériques Taille : ETI Nombre d'employés : 860 Émissions GES : - Scope 1 : 0 tCO₂e (pas de production directe) - Scope 2 : 2 150 tCO₂e - Scope 3 : 8 700 tCO₂e - Total : 10 850 tCO₂e Engagement climatique : - Cible : net zéro en 2035 - Compensation partielle via projets forestiers certifiés Gold Standard Politique RSE : - Formation RSE obligatoire pour 100 % des managers - Rapport extra-financier publié depuis 2017 Certifications : - ISO 50001 (efficacité énergétique) - EcoVadis : médaille d'or Risques : - Cybersécurité et dépendance énergétique analysées comme risques indirects climatiques
Etc...

Exemple : Incompatibilité entre ingrédients de la cosmétique selon ChatGPT

Ingrédient_FR_1	Ingrédient_FR_2	Observation(s)
Acide Ascorbique (Vitamine C)	Acides AHA (ex. Acide Glycolique)	
Acide Azélaïque	Peroxyde de Benzoyle	
Acide Glycolique	Rétinol	
Acide Hyaluronique	Chlorure de Sodium (Sel)	
Acide Hyaluronique	Rétinol	
Acide Mandélique	Acide Lipoïque	
Acide Phytique	Acides Alpha-Hydroxy (AHA)	
Acide Salicylique	Niacinamide (Vitamine B3)	
Alcool Dénaturé	Acides (AHA/BHA)	
Alun (Aluminum Chlorohydrate)	Acide Glycolique	
Céramides	Acide Glycolique	
Extrait de Camomille	Acide Citrique	
Extrait de Camomille	Alcool Dénaturé	
Extrait de Thé vert	Acide Salicylique (BHA)	
Huiles Essentielles	Acide Hyaluronique	
Huiles Essentielles	Peptides (comme les peptides de cuivre)	
Huiles Végétales	Acides Alpha-Lipoïque	
Niacinamide	Acides (AHA/BHA)	
Peroxyde de Benzoyle	Acide Azélaïque	
Peroxyde de Benzoyle	Rétinol	
Probiotiques	Acide Salicylique	
Rétinol	Acide Ascorbique (Vitamine C)	
Rétinol	Acide Lactic (AHA)	
Sulfates	Huiles essentielles	
Tensioactifs (Sulfates)	Acides (AHA/BHA)	
Vitamine C	Acide Salicylique	
Zinc	Acide Citrique	
Zinc (dans les écrans solaires)	Acide Ascorbique (Vitamine C)	